# 자유도와 ddof

Pandas·NumPy 분산/표준편차가 달라지는 이유를 “자유도 → ddof(보정값)” 순서로 이해합니다.

## 1. 왜 자유도와 ddof를 알아야 하나요?

같은 데이터라도 **Pandas**와 **NumPy**에서 **분산(var)**과 **표준편차(std)** 값이 다르게 나오는 경우가 있습니다.
가장 흔한 원인은 **기본 ddof 값 차이**입니다.

> - **자유도(DoF)**: 통계량 계산에서 자유롭게 변할 수 있는 값의 개수입니다.
> - **ddof**: 분산/표준편차 계산에서 분모를 보정하는 “자유도 보정값”입니다.
> - **Pandas 기본값**: ddof=1 (표본 관점)
> - **NumPy 기본값**: ddof=0 (모집단 관점)

## 2. 자유도(Degrees of Freedom) 정의

> **자유도(degrees of freedom)란?**
> 통계량을 계산할 때 **“자유롭게(독립적으로) 변할 수 있는 값의 개수”**를 의미합니다.

### 2-1. 왜 자유도는 $n$이 아니라 $n-1$이 되나요?

분산은 평균을 이용하고, 평균은 합을 이용합니다.
즉, **평균(또는 합)** 이라는 조건이 이미 정해지면 일부 값은 자유롭게 정할 수 없게 됩니다.

### 2-2. 예시: 데이터 3개, 평균이 100인 경우

데이터가 3개이고 평균이 100이라면, 합은 300으로 결정됩니다.

$$x_1 + x_2 + x_3 = 300$$

이때 $x_1$과 $x_2$는 자유롭게 정할 수 있지만,
마지막 값 $x_3$는 다음처럼 자동으로 결정됩니다.

$$x_3 = 300 - (x_1 + x_2)$$

> **결론**
> 데이터가 3개여도 실제로 독립적으로 움직일 수 있는 값은 2개입니다.
> 따라서 자유도는 $n-1$이 됩니다.

## 3. ddof(자유도 보정값) 정의

**ddof(Delta Degrees Of Freedom)란?**
분산/표준편차 계산에서 분모에 적용할 **자유도 보정값**입니다.
즉, 분모는 $n - ddof$가 됩니다.

### 3-1. 분산 공식과 ddof의 관계

$$\text{Variance} = \frac{1}{n - ddof} \sum (x_i - \bar{x})^2$$

| ddof 값 | 분모 | 의미 | 주 사용 상황 |
|---|---|---|---|
| **0** | $n$ | 자유도 보정이 없습니다. | 모집단(전체) 계산 |
| **1** | $n - 1$ | 평균을 이미 사용했으므로 자유도 1을 줄입니다. | 표본으로 모집단 추정 |

## 4. 표본 분산 vs 모집단(모) 분산

아래 표는 동일한 데이터에서 **분모(자유도) 차이** 때문에 값이 달라지는 대표 사례입니다.

| 구분 | 계산식 | 값 | ddof | 기호 |
|---|---|---|---|---|
| **표본 분산** | $\frac{1}{n-1} \sum (x_i - \bar{x})^2$ | **100.5209** | 1(기본값) | $s^2$ |
| **모집단(모) 분산** | $\frac{1}{n} \sum (x_i - \bar{x})^2$ | 92.1442 | 0 | $\sigma^2$ (Sigma squared) |

## 5. 베셀 보정(Bessel's Correction)

**베셀 보정(Bessel's Correction)**
표본 데이터로 계산한 분산은 모집단의 퍼짐을 **작게** 보는 경향이 있습니다.
이를 보정하기 위해 분모를 $n$이 아니라 $n - 1$로 나누어 값이 조금 더 커지도록 조정합니다.
이 보정으로 표본 분산/표본 표준편차는 모집단의 실제 값에 더 가깝게 추정됩니다.

### 5-1. 표준편차 관점 정리

| 구분 | 모 표준편차 (Population) | 표본 표준편차 (Sample) |
|---|---|---|
| **기호** | $\sigma$ (시그마) | $s$ |
| **평균 기호** | $\mu$ (뮤 - 모평균) | $\bar{x}$ (x bar - 표본평균) |
| **공식** | $\sqrt{\frac{1}{n} \sum (x_i - \mu)^2}$ | $\sqrt{\frac{1}{n-1} \sum (x_i - \bar{x})^2}$ |

| 구분 | 모 표준편차 (Population) | 표본 표준편차 (Sample) |
|---|---|---|
| **Pandas** | `ddof=0` | `ddof=1` (기본값) |
| **NumPy** | 기본값 ( `ddof=0` ) | `ddof=1` 지정 필요 |
| **설계 의도** | 수치 계산 및 모집단 분석용 | 데이터 분석 및 표본 추정용 |

## 6. Pandas vs NumPy: 기본 ddof 차이

**기본값 차이**

- **Pandas**는 `ddof=1` 이 기본값입니다. (표본 추정 중심)
- **NumPy**는 `ddof=0` 이 기본값입니다. (모집단 계산 중심)

따라서 같은 데이터라도 **분산/표준편차 값이 다르게 나올 수 있습니다.**

### 6-1. 코드 예시

```
import pandas as pd
import numpy as np

s = pd.Series([10, 20, 30, 40])

# Pandas: 기본 ddof=1 (표본)
print("Pandas var():", s.var())                # 166.66666666666666
print("Pandas var(ddof=0):", s.var(ddof=0))    # 125.0

# NumPy: 기본 ddof=0 (모집단)
arr = s.to_numpy()
print("NumPy var(ddof=1):", np.var(arr, ddof=1)) # 166.66666666666666
print("NumPy var():", np.var(arr))               # 125.0
```

라이브러리가 다르면 기본값이 다를 수 있으므로,
비교/검증할 때는 **ddof를 명시해서 동일 기준으로 맞추는 것이 안전합니다.**

## 7. 한 장 요약

| 키워드 | 한 줄 정의 | 핵심 포인트 |
|---|---|---|
| **자유도(DoF)** | 독립적으로 변할 수 있는 값의 개수입니다. | 평균을 쓰면 자유도가 1 줄어 $n-1$이 됩니다. |
| **ddof** | 분모에서 줄일 자유도 보정값입니다. | 분모는 $n-ddof$로 계산됩니다. |

| 키워드 | 한 줄 정의 | 핵심 포인트 |
|---|---|---|
| **베셀 보정** | 표본 분산의 과소평가를 보정합니다. | $n$ 대신 $n-1$로 나누어 값을 살짝 키웁니다. |
| **Pandas vs NumPy** | 기본 ddof가 다릅니다. | Pandas: 1 / NumPy: 0 이 기본값입니다. |