로지스틱 손실(이진 분류) · 크로스 엔트로피 손실(다중 분류)

0. 왜 손실 함수가 필요한가요?

모델은 "정답에 가깝게" 예측하도록 학습해야 합니다. 이를 위해 우리는 **정답과 예측의 차이를 숫자로 측정** 하는 기준이 필요합니다. 그 기준이 바로 **손실 함수(Loss Function)** 입니다.

> 핵심 손실 값이 **크면** → "많이 틀림" → 가중치를 **더 크게** 업데이트
> 손실 값이 **작으면** → "잘 맞춤" → 가중치를 **조금만** 업데이트

1. 로지스틱 손실 함수 (Logistic Loss Function)

사용 **이진 분류**

예: 스팸/정상, 합격/불합격, 질병/정상

출력 **확률**

$p = P(y = 1 \mid x)$ (클래스 1일 확률)

특징 **확신하고 틀리면 큰 벌점**

오답을 정답처럼 확신할수록 손실이 커짐

1-1) 핵심 개념(문장 정리)

- 정답을 정답에 가깝게 예측할수록 **손실값이 작습니다**.
- 오답을 정답처럼 확신할수록 **손실값이 커집니다**.
- 즉, 모델이 "정확하게 확신"하도록 훈련시키는 손실 함수입니다.

업데이트 관점 손실값이 큰 경우는 예측과 정답의 차이가 크므로 가중치가 크게 조정되어 예측이 정답 쪽으로 빠르게 이동합니다.
이 과정에서 **손실 함수의 기울기(gradient)가 상대적으로 커지는 경향이 있습니다**.

손실값이 작은 경우는 이미 잘 맞추고 있으므로 가중치 업데이트 폭이 작아집니다.

1-2) 확률은 어떻게 나오나요? (시그모이드)

로지스틱 회귀(또는 선형 분류기)는 선형 점수 z를 만든 후 시그모이드 함수로 확률 p를 만듭니다.

$$z = \mathbf{w}^\top \mathbf{x} + b$$

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}$$

1-3) 로지스틱 손실 공식 (0/1 라벨)

정답 $y \in \{0, 1\}$는 0 또는 1를 의미 (이진 분류의 이산(discrete) 값)
예측 확률 $p \in (0, 1)$ 일 때 (0 < p < 1 - 연속적인 확률 값)

$$\mathcal{L}(y, p) = -\left[y \log(p) + (1 - y) \log(1 - p)\right]$$

- 정답이 1이면$(y = 1)$: $\mathcal{L} = -\log(p)$
- 정답이 0이면$(y = 0)$: $\mathcal{L} = -\log(1 - p)$

1-4) 예제(숫자 예시로 이해하기)

상황	정답 y	예측 p (=P(y=1|x))	손실	해석
정답이 1인데 거의 맞춤	1	0.90	$-\log(0.90) \approx 0.10$	손실 작음
정답이 1인데 애매	1	0.50	$-\log(0.50) \approx 0.69$	보통

상황	정답 y	예측 p (=P(y=1|x))	손실	해석
정답이 1인데 거의 0이라고 확신(큰 오답)	1	0.01	$-\log(0.01) \approx 4.61$	**확신하고 틀림 → 큰 벌점**
정답이 0인데 거의 맞춤	0	0.10	$-\log(0.90) \approx 0.10$	손실 작음
정답이 0인데 1이라고 확신(큰 오답)	0	0.99	$-\log(0.01) \approx 4.61$	**확신하고 틀림 → 큰 벌점**

한 줄 요약 로지스틱 손실은 **오답을 "확신"할수록** 로그 때문에 손실이 급격히 커집니다.

2. 크로스 엔트로피 손실 (Cross-Entropy Loss)

사용 **다중 분류**
예: 고양이/개/토끼, 숫자 0~9, 과일 분류

출력 **확률 분포**
각 클래스 확률의 합 = 1

목표 **정답 클래스 확률 ↑**
정답 클래스에 높은 확률이면 손실이 작음

2-1) 핵심 개념(문장 정리)

- 다중 분류에서 사용합니다.
- 모델이 **정답 클래스에 더 높은 확률** 을 부여할수록 손실이 작아집니다.
- 정답 클래스 확률이 낮으면 손실이 커집니다.

2-2) 소프트맥스로 확률 분포 만들기

다중 분류에서는 클래스별 점수(logits) $\mathbf{z} = (z_1, \ldots, z_K)$를 만들고, 소프트맥스(softmax)로 확률 분포 $\hat{\mathbf{p}}$를 만듭니다.

$$\hat{p}_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}} \quad (k = 1, \ldots, K)$$

- K : 클래스 개수
- $\hat{p}_k$: k번째 클래스일 확률

2-3) 크로스 엔트로피 손실 공식

정답을 원-핫(one-hot) 벡터 $\mathbf{y}$, 예측 확률 분포를 $\hat{\mathbf{p}}$라고 할 때:

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{p}}) = -\sum_{k=1}^{K} y_k \log(\hat{p}_k)$$

- 정답 클래스의 y_k만 1이고 나머지는 0이므로
- 결국 손실은 **정답 클래스 확률** 만으로 결정됩니다.

2-4) 예제(3클래스 분류)

클래스가 3개(고양이/개/토끼)이고, 정답이 **개**라고 해봅시다. 정답 원-핫 벡터는 $\mathbf{y} = [0, 1, 0]$ 입니다.

예측 확률(고양이, 개, 토끼)	정답(개)	손실	해석
[0.10, **0.80**, 0.10]	개 확률 0.80 원-핫: $\mathbf{y} = [0, 1, 0]$	$-\sum_{k=1}^{3} y_k \log(\hat{p}_k)$ $= -(0 \log 0.10 + 1 \log 0.80 + 0 \log 0.10)$ $= -\log(0.80) \approx 0.22$	손실 작음

예측 확률(고양이, 개, 토끼)	정답(개)	손실	해석
[0.40, **0.30**, 0.30]	개 확률 0.30 원-핫: $\mathbf{y} = [0, 1, 0]$	$$-\sum_{k=1}^{3} y_k \log(\hat{p}_k)$$ $$= -(0 \log 0.40 + 1 \log 0.30 + 0 \log 0.30)$$ $$= -\log(0.30) \approx 1.20$$	손실 큼
[0.90, **0.05**, 0.05]	개 확률 0.05 원-핫: $\mathbf{y} = [0, 1, 0]$	$$-\sum_{k=1}^{3} y_k \log(\hat{p}_k)$$ $$= -(0 \log 0.90 + 1 \log 0.05 + 0 \log 0.05)$$ $$= -\log(0.05) \approx 3.00$$	**오답에 확신 → 큰 벌점**

한 줄 요약 크로스 엔트로피는 **정답 클래스 확률이 낮을수록** 손실이 커집니다.

3. 로지스틱 손실 vs 크로스 엔트로피 손실

항목	로지스틱 손실 (이진)	크로스 엔트로피 (다중)
문제 유형	이진 분류	다중 분류
확률 출력	$p = P(y = 1 \mid x)$ 하나	$\hat{\mathbf{p}}$ (클래스별 확률 분포-합 1)
확률 변환 함수	Sigmoid	Softmax
손실 함수 (공식 명칭)	Logistic Loss	Cross-Entropy Loss

항목	로지스틱 손실 (이진)	크로스 엔트로피 (다중)
다른 이름 (자주 쓰이는 명칭)	Binary Cross-Entropy Log Loss	Categorical Cross-Entropy Softmax Cross-Entropy
손실 공식	$-\left[y \log p + (1-y)\log(1-p)\right]$	$-\sum_k y_k \log(\hat{p}_k)$
핵심 특징	오답을 확신할수록 손실이 큼	정답 클래스 확률이 낮을수록 손실이 큼

정리

이진 분류는 시그모이드로 확률을 만든 뒤 로지스틱 손실(= 이진 크로스 엔트로피)로 학습합니다.
다중 분류는 소프트맥스로 확률을 만든 뒤 크로스 엔트로피 손실로 학습합니다.